Виды анализа данных

Разведочный и причинно-следственный анализ

Кузнецов Фёдор

11.10.2026

Содержание

1 Введение **1**
1.1 Используемые исследования 2
1.2 Репозиторий проекта 2

2 Разведочный анализ данных **2**
2.1 Что такое разведочный анализ 2
2.1.1 Пример математического представления 2
2.2 Пример исследования: Konopka et al. (2018) 3
2.3 Почему это именно разведочный анализ 3

3 Причинно-следственный анализ **4**
3.1 Что такое причинно-следственный анализ 4
3.2 Пример исследования: Oregon Health Insurance Experiment 4
3.3 Почему это причинно-следственный анализ 4
3.4 Основные результаты исследования 5

4 Визуальное сравнение подходов **5**

5 Сравнение исследований **6**
5.1 Краткая характеристика статей 6
5.2 Сравнение видов анализа 6

6 Вывод **7**

7 Источники **7**

1 Введение

В этой работе рассматриваются два вида анализа данных:

- **разведочный анализ данных** (*Exploratory Data Analysis, EDA*);
- **причинно-следственный анализ** (*causal analysis*).

Цель работы — показать на примерах научных публикаций, чем отличаются эти подходы, какие исследовательские вопросы они решают и почему выбранные статьи относятся именно к соответствующим видам анализа.

1.1 Используемые исследования

В работе используются две научные публикации:

1. **Konopka B. M., Lwow F., Owczarz M., Łaczmański Ł. (2018).** *Exploratory data analysis of a clinical study group: Development of a procedure for exploring multidimensional data*. PLOS ONE, 13(8), e0201950. DOI: 10.1371/journal.pone.0201950
2. **Baicker K., Taubman S. L., Allen H. L. et al. (2013).** *The Oregon Experiment — Effects of Medicaid on Clinical Outcomes*. New England Journal of Medicine, 368, 1713–1722. DOI: 10.1056/NEJMsa1212321

1.2 Репозиторий проекта

Репозиторий проекта на GitHub

2 Разведочный анализ данных

2.1 Что такое разведочный анализ

Разведочный анализ данных применяется тогда, когда исследователю необходимо сначала **понять структуру данных**, а уже затем формулировать более узкие гипотезы.

Типичные задачи EDA:

- изучение распределений признаков;
- поиск выбросов;
- обнаружение групп похожих наблюдений;
- анализ взаимосвязей между переменными;
- снижение размерности;
- визуальное представление сложных многомерных данных.

Иными словами, главный вопрос разведочного анализа можно сформулировать так:

> **Какие закономерности, группы и необычные наблюдения присутствуют в данных?**

2.1.1 Пример математического представления

Одним из распространённых инструментов разведочного анализа является метод главных компонент (*Principal Component Analysis, PCA*).

Проекцию исходных данных можно записать как

$$Z = XW,$$

где:

- X — исходная матрица признаков;
- W — матрица выбранных главных компонент;
- Z — представление объектов в пространстве меньшей размерности.

Для обнаружения многомерных выбросов может использоваться расстояние Махаланобиса:

$$D_M(x) = \sqrt{(x-\mu)^T \Sigma^{-1} (x-\mu)},$$

где μ — вектор средних значений, а Σ — ковариационная матрица.

2.2 Пример исследования: Konopka et al. (2018)

В статье Konopka и соавторов анализировались данные **515 пожилых участников** исследования PolSenior.

Набор данных содержал большое количество биохимических, клинических и социально-демографических характеристик. Авторы стремились понять внутреннюю структуру этих многомерных данных и предложить процедуру их последовательного исследования.

В работе применялись:

1. нормализация данных;
2. обнаружение выбросов с помощью расстояния Махаланобиса;
3. иерархическая кластеризация методом Уорда;
4. метод главных компонент (PCA);
5. визуальное исследование полученных групп и зависимостей.

Авторы подчёркивают роль понимания структуры данных:

> “Thorough knowledge of the structure of analyzed data allows to form detailed scientific hypotheses and research questions.”

2.3 Почему это именно разведочный анализ

Это исследование относится к EDA по нескольким причинам.

Во-первых, авторы **не проверяют одну заранее заданную причинную гипотезу** вида «X вызывает Y».

Во-вторых, основной результат анализа — описание структуры данных:

- какие признаки связаны между собой;
- какие наблюдения отличаются от остальных;
- какие естественные группы можно выделить;
- какие направления вариации являются наиболее важными.

В-третьих, применяемые методы — PCA, кластеризация и поиск выбросов — используются именно для **исследования структуры**, а не для оценки причинного эффекта.

Логику работы можно представить следующим образом:

данные → исследование структуры → поиск закономерностей → формирование новых гипотез.

3 Причинно-следственный анализ

3.1 Что такое причинно-следственный анализ

Причинно-следственный анализ используется, когда исследователь хочет ответить на вопрос:

Вызывает ли изменение фактора X изменение результата Y?

Здесь важно отличать **корреляцию** от **причинности**.

Если переменные X и Y статистически связаны, это ещё не означает, что X является причиной Y. На обе переменные может влиять третий фактор.

Один из способов формально представить причинный эффект — использовать потенциальные исходы.

Средний причинный эффект (*Average Treatment Effect, ATE*) можно записать как

$$ATE = E[Y(1) - Y(0)],$$

где:

- $Y(1)$ — результат при наличии воздействия;
- $Y(0)$ — результат при отсутствии воздействия.

Проблема заключается в том, что для одного и того же человека одновременно наблюдать $Y(1)$ и $Y(0)$ невозможно. Поэтому особенно важен дизайн исследования.

3.2 Пример исследования: Oregon Health Insurance Experiment

В работе Baicker et al. изучались последствия расширения программы медицинского страхования Medicaid в штате Орегон.

Количество мест в программе было ограничено, поэтому возможность подать заявку на Medicaid распределялась с помощью **случайной лотереи**.

Примерно через два года исследователи получили клинические данные:

- для **6387 взрослых**, выбранных лотереей;
- для **5842 взрослых**, не выбранных лотереей.

Измерялись:

- артериальное давление;
- уровень холестерина;
- гликированный гемоглобин;
- наличие депрессивных симптомов;
- использование медицинских услуг;
- финансовые расходы, связанные с лечением.

3.3 Почему это причинно-следственный анализ

Ключевой элемент исследования — **случайная лотерея**.

Она позволяет сформировать группы, различия между которыми не определяются сознательным выбором участников. Благодаря этому снижается влияние факторов, которые могли бы исказить обычное сравнение людей со страховкой и без неё.

Например, при простом наблюдательном сравнении группы могли бы заранее отличаться по:

- уровню дохода;
- состоянию здоровья;
- возрасту;
- отношению к лечению;
- частоте обращений к врачам.

Случайный выбор уменьшает эту проблему.

Важно отметить, что лотерея случайно распределяла **возможность подать заявку на Medicaid**, а не само страховое покрытие. Поэтому авторы использовали случайный выбор как источник внешней вариации и как инструмент для оценки эффекта Medicaid.

Таким образом, исследовательский вопрос имеет причинную форму:

Какие изменения происходят вследствие получения доступа к Medicaid?

3.4 Основные результаты исследования

Авторы не обнаружили статистически значимого улучшения ряда физических показателей здоровья, включая:

- артериальное давление;
- уровень холестерина;
- средний уровень гликированного гемоглобина.

При этом доступ к Medicaid был связан с причинными изменениями по другим исходам:

1. увеличилась вероятность диагностики диабета;
2. увеличилось использование лекарств для лечения диабета;
3. снизилась вероятность положительного скрининга на депрессию;
4. увеличилось использование медицинских услуг;
5. снизилась финансовая нагрузка, связанная с медицинскими расходами.

Поэтому вывод исследования нельзя упрощать до фразы «Medicaid улучшает здоровье».

Более корректно сказать:

> Доступ к Medicaid вызвал заметные изменения в использовании медицинской помощи, финансовой защите и некоторых показателях здоровья, но не привёл к статистически значимому улучшению ряда измеряемых физических показателей за рассматриваемый период.

4 Визуальное сравнение подходов

На рисунке ниже показано главное различие между двумя типами анализа.

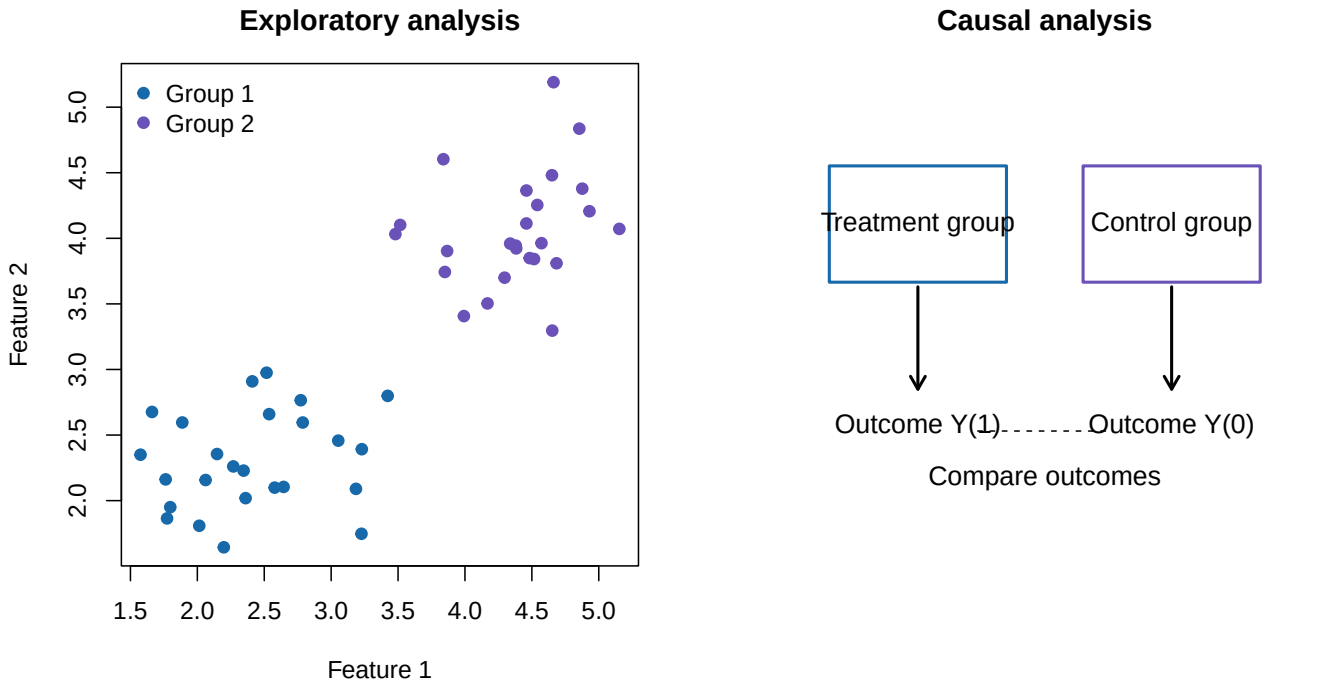


Рис. 1: Концептуальное различие между разведочным и причинно-следственным анализом

5 Сравнение исследований

5.1 Краткая характеристика статей

Таблица 1: Краткая характеристика выбранных исследований

Параметр	Konopka et al. (2018)	Baicker et al. (2013)
Публикация	PLOS ONE	New England Journal of Medicine
Тип анализа	Разведочный	Причинно-следственный
Объект исследования	515 пожилых участников	Участники лотереи Medicaid
Ключевой метод	PCA, кластеризация, выбросы	Случайная лотерея и сравнение групп
Главная цель	Понять структуру многомерных данных	Оценить последствия доступа к Medicaid

5.2 Сравнение видов анализа

Таблица 2: Сравнение разведочного и причинно-следственного анализа

Критерий	Разведочный анализ	Причинно-следственный анализ
Основной вопрос	Что интересного есть в данных?	Вызывает ли X изменение Y?
Цель	Найти структуру и закономерности	Оценить причинный эффект
Типичные методы	Визуализация, PCA, кластеризация, поиск выбросов	Эксперимент, рандомизация, квазиэксперимент, инструментальные переменные
Нужна ли заранее заданная причинная гипотеза	Нет	Да
Тип результата	Группы, связи, выбросы, новые гипотезы	Оценка эффекта воздействия

6 Вывод

Рассмотренные исследования демонстрируют два принципиально разных подхода к анализу данных.

Разведочный анализ используется тогда, когда исследователь хочет понять, как устроены данные. В работе Konopka et al. применяются PCA, кластеризация и поиск выбросов, а результатом становится описание структуры многомерного набора данных и формирование новых исследовательских вопросов.

Причинно-следственный анализ используется тогда, когда требуется оценить эффект конкретного воздействия. В Oregon Health Insurance Experiment случайная лотерея создаёт основу для причинного сравнения и позволяет оценивать последствия доступа к Medicaid.

Главное различие можно сформулировать кратко:

- **EDA:** «Что содержится в данных?»
- **Causal analysis:** «Что изменилось именно из-за воздействия X?»

7 Источники

1. Konopka, B. M., Lwow, F., Owczarz, M., & Łaczmański, Ł. (2018). *Exploratory data analysis of a clinical study group: Development of a procedure for exploring multidimensional data*. **PLOS ONE, 13**(8), e0201950. https://doi.org/10.1371/journal.pone.0201950
2. Baicker, K., Taubman, S. L., Allen, H. L., et al. (2013). *The Oregon Experiment — Effects of Medicaid on Clinical Outcomes*. **New England Journal of Medicine, 368**, 1713–1722. https://doi.org/10.1056/NEJMsa1212321